

Pratique de la Data Science

Cours 1 : Scrapping de données / Apprentissage non-supervisé.

Université Paris Dauphine – Master 2 Ingénierie Statistique et Financière (ISF)

Pierre Fihey – *pierre.fihey@ip-paris.fr*

Plan du cours

I. Sources de données

- Bases de données open-source.
- Scrapping et APIs pour données spécifiques.

II. Apprentissage non supervisé

- Clustering
 - KMEANS
 - Clustering Hiérarchique
 - Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
 - Gaussian Mixture Models (GMM)
- Réduction de dimensionnalité.
 - ACP
 - t-SNE

Plan du cours

I. Sources de données

- Bases de données open-source.
- Scrapping et APIs pour données spécifiques.

II. Apprentissage non supervisé

- Clustering
 - KMEANS
 - Clustering Hiérarchique
 - Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
 - Gaussian Mixture Models (GMM)
- Réduction de dimensionnalité.
 - ACP
 - t-SNE

Plateformes open-source



- **Concours** de Data Science.
- Grande base de **datasets** pour l'entraînement des modèles.
- **Notebooks** mis en lignes par les utilisateurs pour chaque dataset.
- **Intérêts :**
 - Grande variété de domaines.
 - Applications concrètes des problèmes de ML.
 - Datasets propres (généralement préprocessés)



GitHub

- Plateforme de publications de codes **et projets collaboratifs**.
- Grande base de **datasets** (publiés dans chaque projet).

Intérêts :

- Niveau plus avancé (projets et datasets publiés par des chercheurs et développeurs).
- Projets complets (contre juste un notebook sur Kaggle).

Plateformes open-source



Paperswithcode

- Lien entre publications et leurs implémentations.
- **Benchmarks** sur de nombreux datasets.
- Applications moins concrètes.
- **Intérêts :**
 - Niveau très avancé des implémentations.
 - Retrouver les modèles les plus performants sur les problèmes les plus récents en IA



Huggingface

- Plateforme spécialisée pour les modèles d'IA (NLP, Vision, Speech...).
- Grande base de datasets dans ces domaines.
- Grande base de modèles et librairie pour les réentraîner facilement.
- **Intérêts :**
 - Grande variété de domaines.
 - Librairie huggingface utilisée dans toutes les applications de NLP.

Scrapping et APIs

Objectif : Acquérir des données plus spécifiques (et récentes) pour entraînement et mise en production de nos modèles (ex : Ratios financiers, News, statistiques...)

APIs :

- Mises à disposition par les fournisseurs de données.
- Permettent d'extraire les données en temps réel.
- **Standardisées:** Permet d'obtenir des données structurées et faciles à utiliser.

Utilisations d'APIs

Librairie Requests : Requêtes HTTP pour interagir avec une grande majorité des sites WEB (Ex: **NewsAPI**).

- **GET**: Récupérer des données.
- **POST**: Envoi des données.
- **PUT**: Mise à jour des données.
- **DELETE**: Supprime des données.

Librairie Yahoo Finance:

- Principale API financière.
- Permet d'obtenir mouvements de stocks et grande diversité de ratios financiers pour l'analyse du marché.

Limite : Accès limité aux données (souvent journalières).

- Nécessité d'automatiser l'extraction de données: Mise en place de **planificateurs de tâches**.
 - **Windows**: Task scheduler.
 - **Linux et MacOS** : Crontab

Plan du cours

I. Sources de données

- Bases de données open-source.
- Scrapping et APIs pour données spécifiques.

II. Apprentissage non supervisé

- Clustering
 - KMEANS
 - Clustering Hiérarchique
 - Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
 - Gaussian Mixture Models (GMM)
- Réduction de dimensionnalité.
 - ACP
 - t-SNE

Apprentissage non supervisé

Objectif : Découvrir des structures et des relations dans les données.
⇒ Pas de labels disponibles.

Principales applications :

- Clustering
- Réduction de dimensions (PCA, t-SNE).
- Détection d'anomalies.

Plan du cours

I. Sources de données

- Bases de données open-source.
- Scrapping et APIs pour données spécifiques.

II. Apprentissage non supervisé


- **Clustering**
 - KMEANS
 - Clustering Hiérarchique
 - Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
 - Gaussian Mixture Models (GMM)
- Réduction de dimensionnalité.
 - ACP
 - t-SNE

Clustering

Objectif : Identifier des groupes naturels au sein des données.

Applications possibles en finance :

- Identifier des stocks similaires.
- Regrouper des clients en fonction de leur profil de risque.




Clustering des compagnies selon leurs profils de risques (TP2)

KMEANS : Clustering par partitions

Objectif : Minimiser la distance entre chaque point et le centre du cluster auquel il est associé.


Méthode :

1. Initialisation aléatoire de K centroïds.
2. Pour chaque point i , calcul de la distance avec chaque centroïd : $d(x_i, \mu_k) = \sqrt{\sum_{j=1}^p (x_{ij} - \mu_{kj})^2}$
3. Chaque point i est associé au centroïd le plus proche : $C_i = \operatorname{argmin}(d(x_i, \mu_k))$
4. Mise à jour des centroïds : $\mu_k = \frac{1}{n_k} \sum_{x_i \in C_k} x_i$




KMEANS : Etapes

KMeans Iteration: 1



Attribution des clusters : $d(x_i, \mu_k) = \sqrt{\sum_{j=1}^p (x_{ij} - \mu_{kj})^2}$
 $C_i = \arg \min(d(x_i, \mu_k))$

KMeans Iteration: 1



Mise à jour des centroïdes : $\mu_k = \frac{1}{n_k} \sum_{x_i \in C_k} x_i$


KMEANS : Clustering par partitions

Avantages :

- Méthode simple, convergence rapide.
- Efficacité sur données volumineuses (coût faible).
- Visualisation facile $\Rightarrow$ Interprétation intuitive.

Limites :


- Sensibilité aux outliers (peuvent influencer ++ sur les centroïdes).
- Regrouper des clients en fonction de leur profil de risque.



KMEANS : Clustering par partitions

Elbow method : Solution pour déterminer le nombre optimal de clusters.

- On applique K-Means plusieurs fois en faisant varier K.
- On observe l'évolution de l'inertie (somme des distances au carré entre chaque point et son centroïd) en fonction du nombre de cluster.
- Le coude sur la courbe obtenue correspond au nombre optimal de cluster.




Clustering hiérarchique

Objectif : Construire une hiérarchie de clusters.

Méthodes :

- **Ascendante :** De N clusters à 1 cluster. Les clusters les plus proches sont fusionnés à chaque étape.
- **Descendante :** De 1 cluster à N clusters. Les clusters sont divisés à chaque étape.

Dendrogramme: Graphique arborescent qui montre les étapes successives d'agglomérations ou divisions de clusters (output du modèle).



Clustering hiérarchique

Paramètres importants :

- **Distances** entre les points : Euclidienne, Cosinus, Mahalanobis...
- **Agglomération** des clusters: Liaison simple, complète, moyenne, Ward.

Avantages:

- Permet de choisir à posteriori le nombre de clusters.
- Interprétabilité ++.

Limite:

- Coût computationnel élevé (prohibitif pour larges datasets).

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)


Principe : Basé sur la densité locale. Regroupe en clusters les zones densément peuplées et considère les points isolés comme du bruit.

- L'algorithme calcule la **distance** entre chaque point et caractérise ces points en fonction de leur **voisinage**:
 $|N_\epsilon(p)| = \{q \mid d(p, q) \leq \epsilon\}$
 - **Point cœur** : p tq $|N_\epsilon(p)| \geq \text{minsample}$
 - **Points bordures** : $|N_\epsilon(p)| \leq \text{minsample}$ et $\exists q \in N_\epsilon(p)$ tel que q est un point cœur.
 - **Bruit** : $|N_\epsilon(p)| \leq \text{minsample}$ et pas de point cœur dans le voisinage.

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

Méthode :

1. L'algorithme explore le voisinage de chaque point.
2. Dès qu'un point cœur est trouvé, un cluster est formé avec tout son voisinage.
3. D'autres points cœurs sont identifiés récursivement dans son voisinage pour étendre le cluster.
4. L'extension s'arrête quand tout le voisinage est visité.




DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

Avantages :

- Détecte automatiquement le nombre K de clusters.
- Robustes aux outliers (classifiés comme du bruit).

Limite:

- Sensibilité aux paramètres ϵ et $minsample \Rightarrow$ Fusion ou fragmentation excessive.



Clustering basé sur distributions : GMM

Principe : Suppose que les données proviennent de distributions (gaussiennes) différentes.

Méthode :

1. Initialisation: On génère K densités gaussiennes.

2. Iterations: Expectation-Maximization (EM).

1. Calcul des **lois à posteriori**: $\gamma_{ik} = P(z_i = k \mid x_i, \theta) = \frac{\pi_k P(x_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j P(x_i \mid \mu_j, \Sigma_j)}$

2. Mise à jour des paramètres des distributions:


- Maximisation de la vraisemblance : $\mathcal{L}(\theta) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k P(x_i \mid \mu_k, \Sigma_k) \right)$

3. Output: Probabilité d'appartenance à chaque cluster pour chaque observation

Clustering basé sur distributions : GMM

Mise à jour des paramètres (pour chaque gaussienne) :

- Poids $\pi_k = \frac{N_k}{N}$ (N_k : Somme des proba. d'appartenance à k).
- Moyennes $\mu_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{i,k} x_i$
- Covariances $\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{i,k} (x_i - \mu_k)(x_i - \mu_k)^T$



Clustering basé sur distributions : GMM

Avantage :

- Modélisation moins rigide des appartenances aux clusters (probabilité d'appartenance)
⇒ Interprétabilité +.

Limites :

- Très sensible aux initialisations (K et paramètres initiaux).
- Coût computationnel élevé.

Métriques d'évaluation

Silhouette score :

- Calculé pour chaque point :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- **a(i)** la distance moyenne entre i et les points du même cluster ;
- **b(i)** la plus petite distance entre i et les points des autres clusters.

Indice de Calinski-Harabasz :

- Calcul le rapport entre les variances intra-cluster et inter-clusters:

$$CH = \frac{(N - K)B}{(K - 1) \sum_{k=1}^K W_k}$$

- **N** le nombre de points ;
- **K** le nombre de clusters ;
- **B** la variance inter-clusters ;
- **W** la variance au sein des clusters.

Plan du cours

I. Sources de données

- Bases de données open-source.
- Scrapping et APIs pour données spécifiques.

II. Apprentissage non supervisé

- Clustering
 - KMEANS
 - Clustering Hiérarchique
 - Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
 - Gaussian Mixture Models (GMM)
- **Réduction de dimensionnalité.**
 - ACP
 - t-SNE

Réduction de dimensionnalité

Objectif : Transformer les données dans un espace de faible dimension tout en conservant un maximum d'informations.

Intérêts :

- Simplification des données $\Rightarrow$ Suppression des redondances et accélération des calculs.
- Réduction du bruit.
- Visualisation de données multidimensionnelles (en 2D ou 3D).

Analyse en Composantes Principales (ACP)

Objectif : Réduire les dimensions tout en maximisant la variance expliquée dans les dimensions réduites.

Méthode :

1. Centrage des données : $X_{centered} = X - \bar{X}$
2. Calcul Matrice de Covariance : $\Sigma = \frac{1}{N-1} X^T X$
3. Décomposition en Valeurs Propres : $\Sigma = Q \Lambda Q^T$
4. Projection dans l'espace réduit : $Z = X Q_{[:,d]}$ (d le nombre de composantes principales à conserver.)

Variance expliquée par un vecteur propre : $Q_k: V E_k = \frac{\lambda_k}{\sum_{i=1}^p \lambda_i}$.

⇒ Permet de déterminer le nombre de composantes principales à conserver (généralement 95% de la variance expliquée)

t-Distributed Stochastic Neighbor Embedding (t-SNE)

Objectif : Préserver les relations locales lors de la réduction de dimensions.

Méthode :

1. Calcul des distances entre les points et conversion en probabilités (distribution gaussienne) :

$$P_{j|i} = \frac{\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|x_i - x_k\|^2}{2\sigma_i^2}\right)} \implies P_{ij} = \frac{P_{j|i} + P_{i|j}}{2}$$

2. Réduction de dimensions : Peut se faire avec ACP.

3. Calcul des probabilités dans l'espace réduit (distribution t-student) : $Q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$

4. Minimisation de la distance Kullback-Leibler (KL) :

$$\text{KL}(P \parallel Q) = \sum_{i \neq j} P_{ij} \log \frac{P_{ij}}{Q_{ij}}$$